

Omofilia di genere nelle collaborazioni musicali italiane

- [Pattern di collaborazione fra musicisti italiani](#)
 - [Omofilia di genere sessuale e genere musicale su Discogs](#)
 - [Sintesi per il lettore frettoloso](#)
- [1. Sorgenti dati: cosa c'è, cosa manca, cosa si è dovuto costruire](#)
 - [1.1 La fonte](#)
 - [1.2 Tre assenze che hanno cambiato il disegno](#)
 - [1.3 Chi è “musicista italiano”](#)
- [2. Il genere sessuale: come è stato inferito](#)
 - [2.1 Il problema](#)
 - [2.2 Livello 1 — Wikidata agganciato all'identificativo Discogs](#)
 - [2.3 Livello 2 — l'onomastica, costruita dai dati e non da una lista](#)
 - [2.4 Livello 3 — i gruppi si leggono dai membri](#)
 - [2.5 Esito della cascata](#)
 - [2.6 Il pezzo mancante: la validazione manuale](#)
- [3. La rete: come due musicisti diventano collegati](#)
 - [3.1 Il peso dell'arco e perché non tutti i crediti valgono uguale](#)
 - [3.2 Filtri e sottoreti](#)
- [4. Quante sono le donne, e in quale musica \(RQ1\)](#)
 - [4.1 Il confronto con i pattern noti in letteratura](#)
- [5. Omofilia: chi incide con chi \(RQ2\)](#)
 - [5.1 Il quadro generale](#)
 - [5.2 L'omofilia nel tempo: il risultato controintuitivo](#)
 - [5.3 Produttori e interpreti: due mestieri, due omofilie \(RQ5\)](#)
 - [5.4 Omofilia dentro ciascun genere musicale](#)
- [6. Le donne stanno al centro o ai margini? \(RQ3\)](#)
 - [6.1 Il confronto a parità di attività e coorte](#)
 - [6.2 La risposta a RQ3](#)
- [7. Probabilità di collaborare a parità di tutto: l'ERGM \(RQ4\)](#)
 - [7.1 Perché serve e come è stato impostato](#)
 - [7.2 La diagnostica: il modello descrive davvero questa rete?](#)
 - [7.3 Il test pre/post 2000](#)
- [8. Quanto reggono questi risultati](#)
 - [8.1 L'incertezza sul genere sessuale](#)
 - [8.2 Sensibilità ai parametri di costruzione](#)
 - [8.3 Artisti con genere musicale debole](#)
- [Appendice tecnica](#)
 - [A.1 Ambiente](#)
 - [A.2 Una nota sulle prestazioni che ha condizionato il disegno](#)
 - [A.3 Query principali](#)

- [A.4 Tempi di esecuzione](#)
- [A.5 Riproducibilità](#)
- [A.6 Limiti, in ordine di gravità](#)

Pattern di collaborazione fra musicisti italiani

Omofilia di genere sessuale e genere musicale su Discogs

Analisi condotta il 25/09/2026 — fonte unica: dump Discogs locale (PostgreSQL)

Sintesi per il lettore frettoloso

Questo studio ricostruisce **chi ha inciso con chi** fra i musicisti italiani presenti in Discogs e chiede se il genere sessuale delle persone strutturi quelle collaborazioni. La risposta breve è che sì, ma non nel modo che ci si aspetterebbe. L'omofilia esiste ed è statisticamente solidissima, ma è molto più debole della separazione per genere musicale; è **asimmetrica** — sono le donne a fare gruppo fra loro, non gli uomini, all'opposto di quanto riporta la letteratura corrente; e non si è rafforzata dopo il 2000: quello che si è rafforzato è la tendenza della rete a **chiudersi in triangoli**, che produce lo stesso effetto apparente per una ragione diversa.

I numeri

Musicisti italiani identificati	87.229
di cui con genere sessuale determinato	65.093 (74,6%)
Quota di donne fra i determinati	14,8% — un rapporto di 5,77 uomini per ogni donna
Crediti analizzati	3.682.616, di cui 2.360.057 (64,1%) risolti sulla singola traccia
Rete di collaborazione	70.712 artisti collegati, 586.040 legami
Componente gigante	95,4% degli artisti collegati
Assortatività di genere sessuale	r = 0,0432 (IC 95% 0,0399–0,0465)
Assortatività di genere musicale	r = 0,4970
Omofilia di genere pre-2000 → post-2000	0,0406 → 0,0693 (differenza non significativa nell'ERGM)
Omofilia ERGM, donne contro uomini (mediana sulle sottoreti)	0,679 contro 0,074 in log-odds
ERGM	8 sottoreti, 3 modelli ciascuna, 8 convergenti , gwesp incluso

Le cinque cose da sapere

1. **La musica registrata italiana è un mondo di uomini, e lo è rimasta.** 14,8% di donne fra gli artisti con genere determinato significa 5,8 uomini per ogni donna. La quota non cresce in modo monotono nel tempo: parte dal 17,8% per chi debutta negli anni Sessanta, scende al 13,2% negli anni Ottanta e risale al 21,4% per chi debutta dal 2020.
2. **Il genere musicale separa molto più del genere sessuale.** L'assortatività per genere musicale (0,497) è circa 12 volte quella per genere sessuale (0,043). Chi fa jazz incide con chi fa jazz molto più sistematicamente di quanto gli uomini incidano con gli uomini.
3. **L'omofilia di genere sessuale è piccola ma reale.** $r = 0,0432$ sembra poco, ma il modello nullo a gradi preservati dà 0,0001 e l'intervallo di confidenza (0,0399–0,0465) sta tutto sopra lo zero. Non è un effetto di composizione, è struttura.
4. **Sono le donne a fare gruppo, non gli uomini.** È il risultato che contraddice più nettamente l'attesa. Nell'ERGM, che tiene ferme attività, coorte, genere musicale e chiusura triadica, il coefficiente di omofilia femminile è positivo e grande in **tutte e otto** le sottoreti stimate; quello maschile è vicino a zero, e in Rock è perfino negativo. Dove un gruppo è schiacciante maggioranza non ha bisogno di cercarsi; dove è raro, si addensa.
5. **Dopo il 2000 non aumenta l'omofilia: aumenta la chiusura in triangoli.** Descrittivamente l'assortatività sale da 0,0406 a 0,0693. Ma nell'ERGM la differenza fra le due epoche nei termini di genere **non è significativa** ($p = 0,88$ per le donne, 0,60 per gli uomini), mentre il termine di chiusura triadica cresce da 2,22 a 2,89 con $p < 0,0001$. Non è cambiato il criterio con cui si sceglie un collaboratore: è cambiata la forma della rete.
6. **Il pattern "Smurfette" non si osserva.** A parità di pubblicazioni, coorte e genere musicale, l'essere donna non sposta la posizione nella rete su nessuna delle tre misure di centralità usate (sezione 6.2). La disuguaglianza è grande, ma sta nell'**accesso** e nel volume di attività, non nella posizione di chi è riuscito a entrare.

Nota di misura. Tutte le assortatività di genere riportate come principali sono calcolate sui soli archi in cui **entrambi** gli artisti hanno un genere determinato (80,3% degli archi). Includere gli *unknown* come quarta categoria gonfia sistematicamente l'indice, perché gli artisti poco documentati collaborano fra loro più del caso per ragioni di copertura dei dati. Il confronto fra le due misure è in tabella alla sezione 5.1.

Quanto fidarsi

Il genere sessuale non è in nessuna fonte: è **inferito**. Su 74,6% della popolazione si arriva a una determinazione, con 5.203 casi ancorati a Wikidata tramite l'identificativo Discogs (join esatto, nessuna omonimia) e il resto per via onomastica. Il campione di validazione

manuale da 200 casi e lo strumento per misurarne l'errore sono pronti in data/validation_sample.csv; finché non è compilato a mano, le cifre qui sopra vanno lette come stime con un errore non ancora quantificato. Il Monte Carlo della sezione 8.1 mostra comunque che l'omofilia resta positiva **in ogni scenario di imputazione**, compreso quello costruito apposta per minimizzarla.

1. Sorgenti dati: cosa c'è, cosa manca, cosa si è dovuto costruire

1.1 La fonte

L'analisi usa **una sola fonte**: una copia locale del dump Discogs in PostgreSQL (database discogs, 248.153.636 righe nelle tabelle utilizzate). Il disegno iniziale prevedeva anche un secondo database iTunes e una tabella-ponte fra i due; su indicazione del committente iTunes è stato **escluso**. La conseguenza metodologica è netta e va dichiarata: non esiste alcuna verifica incrociata indipendente dell'anagrafica degli artisti, e l'asse di robustezza "unione delle fonti contro sola Discogs" non ha più oggetto. Al suo posto sono stati introdotti due assi alternativi (soglia di italianità e uso o meno dei crediti a livello traccia), discussi nella sezione 8.2.

Tutte le sessioni verso il database hanno girato con `default_transaction_read_only = on`. In PostgreSQL questa impostazione vieta anche le tabelle temporanee, quindi l'estrazione è stata riscritta per non creare **alcun** oggetto sul server: le liste di identificativi calcolate lato Python tornano al database come letterali `int[]`. Nessuna scrittura, di nessun tipo, ha toccato la fonte.

1.2 Tre assenze che hanno cambiato il disegno

L'esplorazione ha trovato tre vuoti nel dump che hanno imposto deviazioni dal piano originale. Vanno messi in chiaro perché limitano ciò che si può concludere.

release_label è vuota (0 righe). Non esiste alcun legame fra pubblicazione ed etichetta discografica. L'euristica prevista per identificare i musicisti italiani a partire dalle *etichette italiane* è quindi inapplicabile, e con essa cade anche ogni analisi per casa discografica. L'italianità si appoggia perciò al solo paese di pubblicazione.

release_genre e release_style sono vuote (0 righe). Il genere musicale è disponibile unicamente attraverso il *master* (`master_genre`), e i master coprono circa il 59% delle pubblicazioni. È la ragione per cui 26,9% della popolazione resta senza genere musicale assegnato.

L'entità "Various Artists" è di fatto assente. In tutto `release_artist` (oltre 92 milioni di righe) i crediti principali attribuiti a un artista di nome "Various*" sono **328**. In questo dump le raccolte non usano il segnaposto consueto: elencano direttamente gli artisti. Il filtro `exclude_various` è quindi quasi inerte (3 pubblicazioni intercettate) e le raccolte vanno riconosciute da un criterio diverso — la presenza di più artisti principali distinti — che è il filtro `exclude_compilations` usato come asse di robustezza.

1.3 Chi è “musicista italiano”

Senza dati di etichetta e senza un campo di nazionalità, l’italianità è stata definita sulla **quota di pubblicazioni italiane** nella carriera di ciascun artista:

Un artista entra nella popolazione se ha almeno 2 pubblicazioni con country = 'Italy', almeno 3 pubblicazioni in totale, e se le italiane sono almeno il 50% del totale.

La regola della quota è la parte che fa il lavoro. Il solo conteggio assoluto produce un elenco dominato da Beethoven, Mozart, Bach, Chopin e Karajan: il repertorio classico viene ristampato in Italia in grandi quantità, e chi guarda solo “quante pubblicazioni italiane” scambia il catalogo per la biografia. La quota li esclude tutti, perché per ciascuno di loro le edizioni italiane sono una frazione minima di un catalogo mondiale.

Il controllo di validità è stato fatto guardando i primi venticinque artisti per volume: Mina, Lucio Battisti, Vasco Rossi, Fabrizio De André, Franco Battiato, Lucio Dalla, Mogol, Renato Zero, Francesco De Gregori, Domenico Modugno, Claudio Villa, più un gruppo di produttori e tecnici italiani realmente attivi (Antonio Baglio, Giovanni Versari, Vincenzo Tempera). Nessun falso positivo evidente.

Restano due limiti strutturali, che nessuna soglia può togliere:

- la regola misura **dove si pubblica**, non **da dove si viene**. Un musicista straniero che abbia lavorato quasi solo per il mercato italiano entra nella popolazione; un italiano emigrato che pubblichi soprattutto all’estero ne esce. La soglia al 50% tiene basso il primo errore a costo di aumentare il secondo;
- Discogs non è un censimento. Sovrarappresenta il vinile, il collezionismo e l’elettronica, e sottorappresenta la musica che non è mai uscita su supporto fisico catalogato. La composizione per genere musicale della sezione 3.2 va letta come composizione *del catalogo Discogs*, non della musica italiana.

Effetto della soglia (misurato): 254.286 artisti hanno almeno due pubblicazioni italiane; applicando quota e minimo, la popolazione scende a **87.229**. Alzando la quota a 0,60 e 0,70 si ottengono 78.448 e 66.113 artisti: la sezione 8.2 mostra che le conclusioni non cambiano.

2. Il genere sessuale: come è stato inferito

2.1 Il problema

Nessuna delle fonti disponibili contiene il genere sessuale delle persone. Va inferito, e l'inferenza va documentata fino in fondo, perché è il punto più fragile dell'intero studio: ogni conclusione sull'omofilia di genere poggia su un'etichetta che nessuno ha dichiarato.

La cascata usata procede dal segnale più solido al più debole, e ogni artista porta con sé **da quale livello** viene la sua etichetta e **con quanta confidenza**.

2.2 Livello 1 — Wikidata agganciato all'identificativo Discogs

Wikidata espone la proprietà P1953, *Discogs artist ID*. Questo consente un **join esatto sull'identificativo**, non sul nome: nessuna omonimia, nessun matching approssimato. Sono state raccolte tutte le entità con P1953 e P21 (genere): **202.478 identificativi Discogs distinti**, con 74 casi ambigui scartati e **zero blocchi persi** su una paginazione ricorsiva per prefisso dell'identificativo.

Di questi, **5.203 ricadono nella nostra popolazione** (6,0%). È una copertura bassa in termini assoluti, e il motivo è ovvio: Wikidata descrive persone notabili, mentre la popolazione Discogs è fatta in larga parte di turnisti, arrangiatori, fonici e produttori che non hanno una voce enciclopedica. Ma sono 5.203 etichette **certe**, ed è su quelle che si regge il livello successivo.

2.3 Livello 2 — l'onomastica, costruita dai dati e non da una lista

Il disegno prevedeva la lista onomastica ISTAT. In questo ambiente non è risultata disponibile come dataset scaricabile; il ripiego adottato è migliore per lo scopo, non peggiore.

Gli stessi 202.478 identificativi Discogs etichettati da Wikidata sono stati ricongiunti ai **nomi** nel database: ne escono **199.812 coppie nome→genere di musicisti**, un corpus onomastico specifico del dominio, molto più ampio dei soli italiani e molto più pertinente di una lista anagrafica generica.

Da qui si ricavano due dizionari, e l'ordine in cui vengono consultati è la scelta metodologicamente più importante di questa sezione:

1. **dizionario italiano** (320 nomi), costruito sui soli artisti italiani etichettati da Wikidata;
2. **gender-guesser con lookup italiano**;

3. **dizionario globale** (2.204 nomi), ma **solo per i nomi che il lookup italiano non riconosce**;
4. gender-guesser globale, come ultima risorsa e con confidenza ridotta.

Il vincolo al punto 3 non è pedanteria. Andrea, Simone, Nicola, Daniele, Michele e Gabriele sono nomi maschili in Italia e femminili nei dizionari dominati dall'inglese: usare il dizionario globale senza quel filtro ribalterebbe il genere di alcune delle prime posizioni dell'onomastica maschile italiana, con un errore sistematico e non casuale, concentrato proprio sui nomi più frequenti. Verificato sui dati: i due dizionari concordano su tutti i 241 nomi che hanno in comune, il che indica che il filtro sta effettivamente tenendo separati i due domini invece di mascherare un conflitto.

2.4 Livello 3 — i gruppi si leggono dai membri

Un nome di band non dice nulla sul genere delle persone. Per i gruppi si guarda perciò la composizione (group_member): se i membri di genere noto sono di entrambi i generi il gruppo è **mixed**, se sono tutti dello stesso genere il gruppo eredita quello, se se ne conoscono meno di due resta unknown. Sono stati risolti **0 gruppi su 0**, di cui 0 misti.

2.5 Esito della cascata

fonte	artisti	quota
onomastico_prior_it	44.618	51,2%
none	22.136	25,4%
onomastico_prior_globale	6.217	7,1%
wikidata_p1953	5.203	6,0%
onomastico_gg_it_male	3.196	3,7%
onomastico_gg_it_female	2.262	2,6%
wikidata_name	1.5	1,7%
onomastico_gg_globale_male	1.162	1,3%
onomastico_gg_globale_female	863	1,0%
onomastico_gg_it_mostly_male	44	0,1%
onomastico_gg_it_mostly_female	28	0,0%

Tabella — Origine dell'etichetta di genere sessuale per ciascun artista. La riga onomastico_prior_it porta da sola la maggior parte del carico: è il dizionario costruito sui 5.203 italiani certi, e bastano 320 nomi propri per coprire quasi la metà della popolazione, perché l'onomastica italiana è fortemente concentrata. none e group_unresolved sono i due volti del non sapere: artisti il cui nome non è un nome di persona riconoscibile (sigle, pseudonimi, progetti) e gruppi di cui non si conoscono abbastanza membri.

Esito finale: 14,8% di donne fra gli artisti con genere determinato, cioè 5,77 uomini per ogni donna, con 25,4% della popolazione che resta indeterminata.

2.6 Il pezzo mancante: la validazione manuale

È stato generato `data/validation_sample.csv`: **200 artisti** estratti in modo stratificato per genere, fascia di confidenza e fonte dell'etichetta, con una colonna `human_gender` vuota da compilare a mano. Lo script `src/score_validation.py` calcola precisione, richiamo, F1 e matrice di confusione per livello della cascata non appena il file è compilato.

Il campione è costruito con **allocazione metà proporzionale e metà uniforme** fra gli strati: la parte proporzionale permette di stimare l'accuratezza complessiva senza riponderare, quella uniforme garantisce abbastanza casi anche nei livelli rari della cascata. Dentro ogni strato si privilegiano nomi propri diversi, perché altrimenti gli strati piccoli si riempiono di omonimi e la validazione misurerebbe l'accuratezza su un nome invece che su un livello.

Su due livelli quel rimedio non basta, e va detto: `onomastico_gg_mostly_female` raccoglie 28 artisti che portano **un solo** nome proprio (Mary), e `onomastico_gg_mostly_male` ne raccoglie 44 con due (Toni, Leonida). Su quei due livelli la validazione potrà dire se quei nomi sono classificati bene, non se il livello funziona in generale. Pesano insieme 72 artisti su 87.229, quindi la cosa non tocca le conclusioni, ma il dato di accuratezza che ne uscirà non va letto come se fosse generalizzabile.

Questo passo **non è stato eseguito**: richiede giudizio umano. Finché non lo si compila, l'errore dell'inferenza di genere è delimitato solo dal Monte Carlo della sezione 8.1, che però misura l'effetto dell'*incertezza sugli unknown*, non quello degli *errori sui noti*. È il limite più serio di questo studio.

3. La rete: come due musicisti diventano collegati

3.1 Il peso dell'arco e perché non tutti i crediti valgono uguale

Un credito Discogs può dire tre cose molto diverse. Può dire “*questa persona suona il basso nel brano B2*”; può dire “*questa persona è l'artista del disco*”; può dire “*questa persona compare nei crediti del disco*”, senza specificare dove. Trattarli come equivalenti significherebbe dare a una coincidenza di copertina lo stesso valore di una sessione documentata.

Ogni credito riceve perciò una **specificità**, e il peso del legame fra due artisti la usa:

ambito	specificità	che cosa significa
track	1.00	credito risolto su una traccia precisa
main	0.70	artista principale della pubblicazione
umbrella	0.30	credito secondario, senza indicazione di tracce

$$w(u,v) = w_t \cdot |\text{tracce condivise}| + w_r \cdot \sum_R s_u(R) s_v(R) \quad w(u,v) = w_t \cdot |\text{tracce condivise}| + w_r \cdot \sum_R s_u(R) s_v(R)$$

Il primo termine premia la collaborazione **documentata sullo stesso brano**; il secondo tiene la co-presenza sulla stessa pubblicazione, scalata dalla specificità di entrambi i crediti. Due turnisti accreditati sulla stessa traccia pesano molto più di due nomi che compaiono genericamente sullo stesso disco.

I crediti a livello traccia vengono da due strade. La prima è `release_track_artist`, che porta un identificativo di traccia globale: **1.932.237 crediti**. La seconda è il campo `tracks` di `release_artist`, che indica le posizioni in forma testuale — A1, 1 to 3, 4, 6, 12 — e va **risolto**: le posizioni si convertono in tracce reali passando per `release_track`. Di 442.050 crediti posizionali ne sono stati risolti 427.820 (96,8%); i restanti usano formule libere (“*all tracks except 1, 13 and 14*”) e sono stati **degradati ad umbrella** anziché interpretati a forza.

Totale: **2.360.057 crediti su 3.682.616 (64,1%) sono risolti a livello di singola traccia.**

3.2 Filtri e sottoreti

Le pubblicazioni con più di 8 artisti accreditati vengono scartate: sono raccolte e cofanetti, dove la co-presenza non indica collaborazione e il numero di coppie esplode in modo quadratico. Il filtro riduce i crediti da 3.682.616 a 586.040.


Le sottoreti per ruolo separano due mestieri diversi: **creative** (produzione, scrittura, arrangiamento, composizione) e **performance** (voce, strumenti, direzione, featuring). Un artista principale senza ruolo esplicito è trattato come interprete, perché è ciò che significa essere l'artista di un disco.

rete	nodi_totali	nodi_con_archi	archi	densita	grado_medio	grado_mediano	grado_max	com
all	87.229	70.712	586.040	0,000234	16,575404	7,000000	2.258	1.20
creative	87.229	30.440	199.832	0,000431	13,129566	4,000000	1.348	1.53
performance	87.229	49.152	211.751	0,000175	8,616170	4,000000	598	2.49

Tabella — Descrittive delle tre reti di collaborazione

Dati completi in tables/t2_rete_descrittive.csv e tables/t2_rete_descrittive.tex.


La rete complessiva è **sparsa e molto connessa**: densità dell'ordine di 0,000234, ma una componente gigante che assorbe 95,4% degli artisti collegati. È la firma tipica di un mondo professionale in cui quasi nessuno lavora isolato e quasi nessuno lavora con tutti. La rete creative è più piccola e più densa di quella performance: produttori e autori formano un nucleo più ristretto e più intrecciato di quello degli esecutori — un dato che conta per la lettura della sezione 5.3, dove i due ruoli mostrano omofilie diverse.




Distribuzione di grado e forza. Su scala doppio-logaritmica entrambe le distribuzioni scendono con una pendenza quasi rettilinea su più ordini di grandezza: la stragrande maggioranza degli artisti ha pochissimi collaboratori, mentre una minoranza sottile ne ha centinaia. La forza — che somma i pesi, quindi conta quante volte si è collaborato e quanto erano specifici i crediti — ha una coda ancora più lunga del grado: i grandi collaboratori non hanno solo molti partner, hanno relazioni molto più intense. È il substrato strutturale su cui va letta la sezione 6.1: in una rete così diseguale, la domanda ‘le donne stanno al centro?’ va sempre posta a parità di attività, perché il numero di pubblicazioni da solo spiega già gran parte della centralità.

Le analisi che seguono girano sulla **componente gigante**, perché le misure di centralità e le distanze non sono definite fra componenti separate. La quota esclusa è 4,6% degli artisti collegati.

4. Quante sono le donne, e in quale musica (RQ1)



La quota di donne per decennio di debutto. La linea non è la storia di un progresso. Parte dal 17,8% per chi debutta negli anni Sessanta, scende fino al 13,2% negli anni Ottanta — il minimo della serie — e risale solo di recente, fino al 21,4% per chi debutta dal 2020. La discesa degli anni Settanta e Ottanta merita cautela prima di leggerla come un arretramento reale: coincide con l’espansione massiccia del catalogo Discogs in quegli anni, cioè con l’ingresso in massa di crediti tecnici e di produzione — mestieri quasi interamente maschili — che diluiscono una quota calcolata su tutti i crediti e non sui soli interpreti. La risalita recente è invece coerente sia in ampiezza sia in direzione con quanto si osserva negli altri cataloghi musicali. In ogni decennio, comunque, la banda di confidenza resta lontanissima dalla parità.



Quota di donne per genere musicale e decennio. I pannelli mostrano che non esiste una singola traiettoria di genere: esistono generi musicali con storie diverse. Il livello di partenza conta più della pendenza — un genere che parte basso tende a restare basso attraverso i decenni, il che è esattamente la firma di una segregazione che si riproduce per reclutamento piuttosto che dissolversi col tempo.

musical_genre	cohort_decade	n_artisti	n_noti	n_donne	quota_donne	ci_lo	ci_hi	rapporto_uomini_donne
Blues	1.940	1	1,000	0,000	0,000	0,000	0,793	n.d.
Blues	1.950	3	0,000	0,000	n.d.	n.d.	n.d.	n.d.
Blues	1.960	17	13,000	1,000	0,077	0,014	0,333	12,000
Blues	1.970	61	54,000	9,000	0,167	0,090	0,287	5,000
Blues	1.980	105	98,000	15,000	0,153	0,095	0,237	5,533
Blues	1.990	129	106,000	15,000	0,142	0,088	0,220	6,067
Blues	2.000	137	121,000	21,000	0,174	0,116	0,251	4,762
Blues	2.010	141	114,000	22,000	0,193	0,131	0,275	4,182
Blues	2.020	22	17,000	4,000	0,235	0,096	0,473	3,250
Brass & Military	1.940	24	14,000	0,000	0,000	0,000	0,215	n.d.
Brass & Military	1.950	10	6,000	0,000	0,000	0,000	0,390	n.d.
Brass & Military	1.960	38	18,000	2,000	0,111	0,031	0,328	8,000
Brass & Military	1.970	13	6,000	0,000	0,000	0,000	0,390	n.d.
Brass & Military	1.980	9	5,000	0,000	0,000	0,000	0,434	n.d.
Brass & Military	1.990	12	9,000	0,000	0,000	0,000	0,299	n.d.
Brass & Military	2.000	1	1,000	0,000	0,000	0,000	0,793	n.d.
Brass & Military	2.010	1	0,000	0,000	n.d.	n.d.	n.d.	n.d.
Children's	1.940	33	23,000	10,000	0,435	0,256	0,632	1,300
Children's	1.950	79	72,000	24,000	0,333	0,235	0,448	2,000
Children's	1.960	208	173,000	66,000	0,382	0,312	0,456	1,621
Children's	1.970	170	131,000	70,000	0,534	0,449	0,618	0,871
Children's	1.980	85	53,000	24,000	0,453	0,327	0,585	1,208
Children's	1.990	60	45,000	16,000	0,356	0,232	0,502	1,812
Children's	2.000	27	23,000	7,000	0,304	0,156	0,509	2,286
Children's	2.010	13	9,000	2,000	0,222	0,063	0,547	3,500

Tabella — Quota di donne per genere musicale e decennio di debutto, con intervalli di Wilson al 95%

Mostrate le prime 25 righe di 141; la tabella completa è in `tables/t3_quota_donne_genere_decennio.csv` e `tables/t3_quota_donne_genere_decennio.tex`.

4.1 Il confronto con i pattern noti in letteratura


Il riferimento consueto per l'hip hop è un rapporto intorno a **4 uomini per ogni donna**. Nei dati italiani il rapporto è **10,4 a 1** (8,8% di donne): sensibilmente **più squilibrato** del riferimento internazionale. Due letture non alternative: la scena hip hop italiana censita da Discogs è più piccola e più recente, quindi più esposta al fatto che i ruoli di produzione — dove le donne sono più rare — pesino relativamente di più; e il conteggio qui include tutti i crediti, non solo gli interpreti principali, il che abbassa la quota rispetto alle statistiche basate sulle classifiche.

All'estremo opposto, **Classical** (24,7%) e **Children's** (41,3%) sono i generi con la presenza femminile più alta — il secondo sopra il 41%, l'unico dell'intero corpus in cui le donne si avvicinano alla metà. La distanza fra Children's e Hip Hop, a parità di popolazione e di metodo, è di oltre 33 punti percentuali: il genere musicale è il predittore più forte della presenza femminile in tutto questo studio.

Rock (10,5%) e Electronic (14,2%), che insieme fanno la parte maggiore della popolazione, stanno entrambi sotto la media generale. È su queste due scene, per peso numerico, che si decide la quota complessiva.

5. Omofilia: chi incide con chi (RQ2)

5.1 Il quadro generale



Chi collabora con chi, rispetto al caso. Ogni cella è il rapporto fra i legami osservati e quelli attesi sotto un modello nullo che conserva esattamente il grado di ogni artista e la composizione della popolazione: l'unica cosa randomizzata è *chi sta con chi*. Un valore di 1 significa 'come il caso', sopra 1 significa più del previsto. La diagonale sopra 1 e le celle fuori diagonale sotto 1 sono la definizione operativa di omofilia. Vale la pena notare che anche la cella unknown-unknown si discosta da 1: non è un fatto sociale ma un fatto di copertura dei dati — gli artisti su cui non sappiamo nulla tendono a stare insieme perché condividono le stesse caratteristiche che li rendono poco documentati (pochi crediti, ruoli minori, epoche marginali). È precisamente questo il motivo per cui l'ERGM della sezione 7 esclude i nodi unknown invece di trattarli come una categoria.

attributo	r_osservato	r_pesato	r_null_medio	r_null_sd	z
gender	0,0810	0,1254	-0,0000	0,0010	81,4605
musical_genre	0,4970	0,6675	-0,0001	0,0006	790,6131

Tabella — Assortatività osservata e sotto modello nullo

Dati completi in `tables/t3_assortativita_globale.csv` e `tables/t3_assortativita_globale.tex`.

sottorete	strato	attr.	categorie	archi	quota archi	r	ci_lo	ci_hi
all	tutto	gender	determinati soltanto	470.690	0,8032	0,0432	0,0399	0,0465
all	tutto	gender	tutte le categorie	586.040	1,0000	0,0810	0,0788	0,0834
all	tutto	musical_genre	determinati soltanto	503.971	0,8600	0,5622	0,5606	0,5638
all	tutto	musical_genre	tutte le categorie	586.040	1,0000	0,4970	0,4955	0,4984
all	pre2000	gender	determinati soltanto	333.067	0,8444	0,0406	0,0367	0,0443
all	pre2000	gender	tutte le categorie	394.423	1,0000	0,0576	0,0548	0,0605
all	pre2000	musical_genre	determinati soltanto	362.127	0,9181	0,5103	0,5082	0,5124
all	pre2000	musical_genre	tutte le categorie	394.423	1,0000	0,4704	0,4685	0,4721
all	post2000	gender	determinati soltanto	61.015	0,6563	0,0693	0,0598	0,0788
all	post2000	gender	tutte le categorie	92.968	1,0000	0,1479	0,1416	0,1533
all	post2000	musical_genre	determinati soltanto	64.388	0,6926	0,7101	0,7062	0,7141
all	post2000	musical_genre	tutte le categorie	92.968	1,0000	0,5445	0,5407	0,5482
creative	tutto	gender	determinati soltanto	179.908	0,9003	0,0224	0,0172	0,0279
creative	tutto	gender	tutte le categorie	199.832	1,0000	0,0703	0,0658	0,0750
creative	tutto	musical_genre	determinati soltanto	184.147	0,9215	0,5770	0,5743	0,5799
creative	tutto	musical_genre	tutte le categorie	199.832	1,0000	0,5351	0,5323	0,5377
creative	pre2000	gender	determinati soltanto	146.391	0,9325	0,0224	0,0165	0,0282
creative	pre2000	gender	tutte le categorie	156.982	1,0000	0,0269	0,0224	0,0316
creative	pre2000	musical_genre	determinati soltanto	149.499	0,9523	0,5209	0,5177	0,5243
creative	pre2000	musical_genre	tutte le categorie	156.982	1,0000	0,4945	0,4914	0,4977
creative	post2000	gender	determinati soltanto	13.668	0,7079	0,0444	0,0227	0,0655

sottorete	strato	attr.	categorie	archi	quota archi	r	ci_lo	ci_hi
creative	post2000	gender	tutte le categorie	19.308	1,0000	0,1616	0,1478	0,1753
creative	post2000	musical_genre	determinati soltanto	14.659	0,7592	0,7868	0,7788	0,7953
creative	post2000	musical_genre	tutte le categorie	19.308	1,0000	0,6235	0,6145	0,6320
performance	tutto	gender	determinati soltanto	160.881	0,7598	0,1054	0,0996	0,1115
performance	tutto	gender	tutte le categorie	211.751	1,0000	0,1704	0,1667	0,1741
performance	tutto	musical_genre	determinati soltanto	171.934	0,8120	0,6153	0,6125	0,6177
performance	tutto	musical_genre	tutte le categorie	211.751	1,0000	0,5305	0,5279	0,5327
performance	pre2000	gender	determinati soltanto	95.250	0,8164	0,1106	0,1028	0,1180
performance	pre2000	gender	tutte le categorie	116.673	1,0000	0,1733	0,1679	0,1785
performance	pre2000	musical_genre	determinati soltanto	103.792	0,8896	0,5612	0,5582	0,5647
performance	pre2000	musical_genre	tutte le categorie	116.673	1,0000	0,5132	0,5101	0,5164
performance	post2000	gender	determinati soltanto	31.344	0,6306	0,1050	0,0913	0,1180
performance	post2000	gender	tutte le categorie	49.702	1,0000	0,1985	0,1909	0,2066
performance	post2000	musical_genre	determinati soltanto	33.316	0,6703	0,7482	0,7428	0,7533
performance	post2000	musical_genre	tutte le categorie	49.702	1,0000	0,5737	0,5685	0,5787

Tabella — Assortatività calcolata sui soli nodi con attributo determinato contro il calcolo che tratta ‘indeterminato’ come una categoria, per il genere sessuale e per quello musicale

Dati completi in tables/t3_assortativita_MF_vs_tutte.csv e tables/t3_assortativita_MF_vs_tutte.tex.

Una precisazione di misura che cambia i numeri

Le due tabelle vanno lette insieme, perché la seconda corregge la prima.

Trattare unknown come una quarta categoria alla pari di M ed F gonfia l’assortatività: la cella unknown-unknown sta molto sopra l’atteso, ma non perché quelle persone si

cerchino fra loro. Si cercano fra loro le caratteristiche che le rendono poco documentate — pochi crediti, ruoli minori, epoche marginali, pseudonimi — e sono le stesse che rendono difficile inferirne il genere. È copertura dei dati che si traveste da struttura sociale.

La misura di riferimento restringe perciò il calcolo agli archi in cui entrambi gli estremi hanno genere determinato: **80,3% degli archi**. La differenza non è cosmetica: **r passa da 0,0810 a 0,0432**, cioè un terzo dell'omofilia apparente era artefatto.


Lo stesso controllo è stato fatto sul **genere musicale**, dove 'Unknown' è altrettanto presente, e dà il risultato **opposto**: togliendo gli indeterminati l'assortatività sale da 0,4970 a 0,5622. Il motivo è che gli artisti senza genere musicale assegnato non si aggregano fra loro per genere — non ne hanno uno — e quindi diluiscono la diagonale invece di gonfiarla. Riportare entrambi i confronti serve a chiarire che l'esclusione degli indeterminati è una scelta di metodo applicata in modo uniforme, non un accorgimento adottato dove conveniva: sul genere sessuale abbassa il risultato, sul genere musicale lo alza.

Il risultato centrale

L'assortatività per **genere musicale** vale 0,497. È un valore molto alto: le carriere si svolgono dentro un genere e le collaborazioni seguono i confini del genere quasi come se fossero confini di settore.


L'assortatività per **genere sessuale** vale 0,0432, circa 12 volte meno, con intervallo di confidenza 0,0399-0,0465 e modello nullo a 0,0001. Preso da solo il numero sembra trascurabile; non lo è, perché su 586.040 archi anche un effetto piccolo è misurato con precisione elevata e l'intervallo sta interamente sopra lo zero.

La lettura sostanziale è che **il genere sessuale struttura le collaborazioni, ma molto meno di quanto faccia la specializzazione musicale**. Chi cerca un bassista lo cerca nel proprio giro musicale molto più sistematicamente di quanto lo cerchi del proprio sesso. Questo non rende l'omofilia di genere irrilevante — rende il genere musicale il canale attraverso cui essa prevalentemente opera, come mostra il paragrafo seguente.



Omofilia per genere musicale. La diagonale domina l'immagine. I generi più chiusi non sono necessariamente i più grandi: la chiusura misura quanto una scena recluta al proprio interno, non quanto è popolosa. Le celle fuori diagonale che superano 1 indicano le coppie di generi fra cui esiste un traffico reale di musicisti — i confini permeabili del sistema.

5.2 L'omofilia nel tempo: il risultato controintuitivo



Omofilia di genere per sottorete di ruolo ed epoca. Il punto è il valore osservato, la barra l'intervallo di confidenza bootstrap al 95%, il trattino verticale il valore del modello nullo. L'attesa, dalla letteratura, era un **allentamento** dopo il 2000. Sui soli nodi con genere determinato i dati dicono l'opposto, ma con ampiezza molto più contenuta di quanto suggerisca la misura a quattro categorie mostrata in figura: 0,0406 contro 0,0693.

Prima di interpretarlo va ripulito. Sulla misura ingenua a quattro categorie il salto è spettacolare, da 0,0576 a 0,1479: più che raddoppiato. Sui soli nodi con genere determinato si riduce a 0,0406 → 0,0693. La ragione è che la quota di archi utilizzabili crolla fra le due epoche — dal 84,4% al 65,6% — perché gli artisti recenti sono mediamente meno documentati: più unknown, quindi più apparente omofilia spuria.

Quel che resta dopo la correzione è comunque un aumento, con intervalli (0,0367–0,0443 contro 0,0598–0,0788) che non si sovrappongono. Il risultato regge, ma va raccontato per quello che è: un aumento moderato, non un raddoppio.

E l'aumento non è diffuso: viene tutto da una parte sola della rete. Scomponendo per ruolo, l'omofilia dei ruoli di esecuzione è sostanzialmente piatta nel tempo (0,1106 prima del 2000, 0,1050 dopo), mentre quella dei ruoli creativi **raddoppia**, da 0,0224 a

0,0444. Qualunque spiegazione dell'aumento deve perciò riguardare il modo in cui si produce e si scrive musica, non il modo in cui la si suona.

Restano due letture possibili, e i dati qui presenti non permettono di scegliere fra loro in modo definitivo.

Prima lettura — è reale. Dopo il 2000 cambia il modo di produrre musica: la registrazione si decentra, gli studi grandi con organici misti e obbligati lasciano spazio a progetti piccoli, costruiti su reti personali. Reti personali significa reti più omofile. In questa lettura l'aumento non è un arretramento culturale ma l'effetto strutturale di una tecnologia di produzione diversa — e il fatto che riguardi i soli ruoli creativi, che sono precisamente quelli toccati dalla decentralizzazione degli studi, depone a favore di questa spiegazione.

Seconda lettura — è composizione. L'indice r di Newman dipende dalle marginali. Post-2000 ci sono più donne, quindi più occasioni di legame donna-donna; a parità di propensione, un gruppo minoritario più numeroso produce meccanicamente un'assortatività misurata più alta. Il modello nullo a gradi preservati corregge per il grado, **non** per questa asimmetria di composizione fra epoche.

È esattamente per dirimere questo punto che serve l'ERGM, e **il verdetto è arrivato**: una volta controllata la tendenza della rete a chiudere i triangoli, la differenza di omofilia di genere fra le due epoche **non è statisticamente distinguibile da zero** (per le donne 0,709 contro 0,776, $p = 0,88$; per gli uomini 0,137 contro 0,080, $p = 0,60$).

Ciò che aumenta davvero, e in modo nettissimo, è la **chiusura triadica**: il coefficiente g_{wesp} passa da 2,217 a 2,892 ($p < 0,0001$). La musica registrata italiana dopo il 2000 non è diventata più omofila per genere: è diventata più **chiusa in triangoli**. Si lavora sempre di più dentro gruppi fitti di persone che si conoscono già tutte fra loro. In un ambiente dove le donne sono il 14,8%, una struttura più triangolare produce meccanicamente più legami donna-donna osservati, e quindi un'assortatività misurata più alta — senza che nessuno abbia cambiato criterio nello scegliere con chi lavorare.

È la risposta più interessante dello studio, perché sposta l'oggetto: il problema non è una preferenza di genere che si è rafforzata, ma una struttura di reclutamento che si è chiusa. Sono due cose diverse anche dal punto di vista di chi volesse intervenire. I dettagli del test sono nella sezione 7.3.


5.3 Produttori e interpreti: due mestieri, due omofilie (RQ5)

La distinzione fra ruoli creativi (produzione, scrittura, arrangiamento) e ruoli di esecuzione (voce, strumenti, direzione) è la domanda RQ5, e la risposta è netta: sui soli nodi con genere determinato l'omofilia vale **0,0224 nella rete creativa** contro **0,1054 in quella di esecuzione**.

La collaborazione creativa è quindi *meno* segregata per genere di quella esecutiva, di un fattore 4,7. È un risultato che va letto insieme al dato di composizione: i ruoli creativi sono in assoluto i più maschili dell'intero corpus, e proprio per questo l'omofilia misurata

vi risulta bassa — dove la maggioranza è schiacciante non c'è quasi spazio per discostarsi dal caso. La segregazione dei ruoli creativi si manifesta nel **chi entra**, non nel **chi lavora con chi**; quella dei ruoli esecutivi, dove le donne sono più presenti, si manifesta anche nella struttura delle collaborazioni. Sono due forme diverse di chiusura, e confonderle porterebbe a concludere che la produzione musicale sia il luogo più aperto del sistema, che è l'opposto di quanto dicono i conteggi.

5.4 Omofilia dentro ciascun genere musicale



A sinistra l'omofilia di genere sessuale calcolata separatamente dentro ciascun genere musicale, con il modello nullo come riferimento. **A destra** la scomposizione della diagonale: quanto i legami uomo-uomo e quanto i legami donna-donna superano l'atteso. La lettura congiunta dei due pannelli è il cuore di RQ2. Un valore osservato/atteso vicino a 1 per gli uomini e molto sopra 1 per le donne descrive una situazione precisa: gli uomini non si cercano fra loro più del caso — non ne hanno bisogno, sono la maggioranza e il caso li mette già insieme — mentre le donne si aggregano fra loro molto più del previsto. È la forma che l'omofilia assume quando una minoranza opera dentro una maggioranza: non segregazione simmetrica, ma addensamento del gruppo minoritario.

genere_musicale	archi	r_gender	ci_lo	ci_hi	r_null	oe_MM	oe_FF	n_artisti	quota_donne
Electronic	128.659	0,0692	0,0643	0,0739	0,0000	1,0241	1,3588	19.969	0,0985
Pop	109.924	0,0233	0,0183	0,0284	0,0001	1,0028	1,3115	9.446	0,1637
Rock	41.007	0,1608	0,1515	0,1708	0,0001	1,0353	1,7579	16.617	0,0806
Hip Hop	17.507	0,1429	0,1277	0,1567	-0,0001	1,0445	2,1820	1.822	0,0565
Folk, World, & Country	13.639	0,0769	0,0625	0,0919	-0,0005	1,0175	1,5411	4.863	0,1143
Jazz	11.762	0,0333	0,0171	0,0497	0,0001	1,0044	1,5144	3.124	0,1172
Classical	5.264	0,0512	0,0292	0,0739	-0,0002	1,0166	1,2704	3.674	0,2131
Stage & Screen	2.693	0,0186	-0,0141	0,0548	-0,0019	1,0035	1,1863	641	0,1700
Non-Music	1.106	0,0762	0,0171	0,1351	-0,0002	1,0151	1,3163	477	0,1698
Children's	1.075	0,0340	-0,0101	0,0780	-0,0005	1,0120	1,0144	676	0,3240

Tabella — Omofilia di genere sessuale entro ciascun genere musicale (RQ2)

Dati completi in tables/t3_omofilia_per_genere_musicale.csv e tables/t3_omofilia_per_genere_musicale.tex.

Questo è il punto su cui il dato italiano **contraddice l'aspettativa corrente**. La letteratura riporta di norma un'omofilia più forte *fra gli uomini*. Qui il rapporto osservato/atteso donna-donna è sistematicamente **maggiore** di quello uomo-uomo. La spiegazione non è che le donne siano più chiuse: è che con una quota femminile del 14,8% il valore atteso per un legame donna-donna sotto casualità è bassissimo, e basta un modesto addensamento reale per produrre un rapporto elevato. L'indice uomo-uomo, al contrario, è schiacciato verso 1 perché la maggioranza non può discostarsi molto dal caso. **I due indici non sono confrontabili come se misurassero la stessa cosa**, ed è l'ERGM — che stima una propensione e non un rapporto — a fornire il confronto corretto.


6. Le donne stanno al centro o ai margini? (RQ3)

La domanda che la letteratura chiama *pattern Smurfette* è se le donne, dove ci sono, occupino posizioni strutturalmente periferiche: presenti quanto basta, mai al centro.

gender	n	eigenvector_mediana	eigenvector_media	betweenness_mediana	coreness_mediana	coreness
F	6.961	0,000000	0,000055	0,000000	6,000000	9,011000
M	44.869	0,000000	0,000174	0,000002	6,000000	10,020000

Tabella — Posizione nella componente gigante per genere sessuale

Dati completi in `tables/t3_posizione_per_genere.csv` e `tables/t3_posizione_per_genere.tex`.



Coreness mediana per genere sessuale, dentro ciascun genere musicale. La coreness dice a quale strato del nucleo denso della rete una persona appartiene: è una misura di appartenenza al centro più robusta della centralità di grado, perché non si lascia gonfiare da chi ha molti collaboratori occasionali. Le barre affiancate permettono il confronto diretto a parità di genere musicale, che è il confronto giusto: paragonare una cantante pop a un turnista jazz non direbbe nulla sul genere sessuale e molto sulla struttura delle due scene.

musical_genre	gender	n	coreness_mediana	eigenvector_mediana
Blues	F	53	5,000000	0,000000
Blues	M	305	6,000000	0,000000
Brass & Military	F	2	7,500000	0,000000
Brass & Military	M	46	8,500000	0,000000
Children's	F	154	8,000000	0,000001
Children's	M	245	7,000000	0,000001
Classical	F	436	4,000000	0,000000
Classical	M	1.642	5,000000	0,000000
Electronic	F	1.722	7,000000	0,000000
Electronic	M	10.938	8,000000	0,000000
Folk, World, & Country	F	413	7,000000	0,000000
Folk, World, & Country	M	2.760	7,000000	0,000000
Funk / Soul	F	77	6,000000	0,000000
Funk / Soul	M	473	7,000000	0,000000
Hip Hop	F	72	10,000000	0,000000
Hip Hop	M	966	15,000000	0,000000
Jazz	F	245	7,000000	0,000000
Jazz	M	1.919	9,000000	0,000000
Latin	F	29	7,000000	0,000000
Latin	M	150	7,500000	0,000000
Non-Music	F	62	5,500000	0,000000
Non-Music	M	298	7,000000	0,000000
Pop	F	1.150	11,000000	0,000004
Pop	M	5.608	13,000000	0,000003
Reggae	F	14	4,500000	0,000000
Reggae	M	166	6,000000	0,000000
Rock	F	774	5,000000	0,000000
Rock	M	8.587	6,000000	0,000000
Stage & Screen	F	88	9,000000	0,000002
Stage & Screen	M	394	11,000000	0,000002

Tabella — Posizione nella rete per genere sessuale entro genere musicale

Dati completi in tables/t3_posizione_per_genere_musicale.csv e tables/t3_posizione_per_genere_musicale.tex.

6.1 Il confronto a parità di attività e coorte

Le mediane grezze non bastano. Chi pubblica di più è più centrale, e le donne della popolazione pubblicano meno: la mediana delle pubblicazioni è 8 per le donne contro 9 per gli uomini, e la coreness mediana segue (6 contro 6). Senza controllare per l'attività si misurerebbe la differenza di quanto si pubblica e la si chiamerebbe differenza di posizione.

La regressione confronta perciò persone con la stessa attività, la stessa coorte di debutto e lo stesso genere musicale.

termine	coef	se	z	p	ci_lo	ci_hi	esito
Intercept	0,8390	0,0966	8,6891	0,0000	0,6497	1,0282	eigenvector
C(gender)[T.F]	0,1801	0,1754	1,0265	0,3047	-0,1638	0,5239	eigenvector
C(genere)[T.Blues]	-0,0114	0,0764	-0,1498	0,8809	-0,1612	0,1383	eigenvector
C(genere)[T.Children's]	-0,1781	0,1203	-1,4802	0,1388	-0,4140	0,0577	eigenvector
C(genere)[T.Classical]	-0,6635	0,0683	-9,7184	0,0000	-0,7974	-0,5297	eigenvector
C(genere)[T.Electronic]	-0,1863	0,0627	-2,9721	0,0030	-0,3092	-0,0634	eigenvector
C(genere)[T.Folk, World, & Country]	-0,2480	0,0663	-3,7436	0,0002	-0,3779	-0,1182	eigenvector
C(genere)[T.Funk / Soul]	0,0681	0,0760	0,8962	0,3702	-0,0808	0,2171	eigenvector
C(genere)[T.Hip Hop]	-0,3351	0,0680	-4,9293	0,0000	-0,4683	-0,2018	eigenvector
C(genere)[T.Jazz]	-0,1980	0,0674	-2,9391	0,0033	-0,3300	-0,0660	eigenvector
C(genere)[T.Non-Music]	-1,4207	0,0969	-14,6663	0,0000	-1,6105	-1,2308	eigenvector
C(genere)[T.Pop]	1,0434	0,0662	15,7589	0,0000	0,9137	1,1732	eigenvector
C(genere)[T.Rock]	0,0077	0,0629	0,1223	0,9027	-0,1156	0,1310	eigenvector
C(genere)[T.Stage & Screen]	0,3258	0,0914	3,5651	0,0004	0,1467	0,5049	eigenvector
C(coorte)[T.1950]	0,2381	0,0906	2,6284	0,0086	0,0605	0,4156	eigenvector
C(coorte)[T.1960]	-0,1393	0,0793	-1,7560	0,0791	-0,2947	0,0162	eigenvector
C(coorte)[T.1970]	-1,2591	0,0757	-16,6331	0,0000	-1,4075	-1,1108	eigenvector
C(coorte)[T.1980]	-1,8311	0,0739	-24,7652	0,0000	-1,9760	-1,6862	eigenvector
C(coorte)[T.1990]	-2,0707	0,0735	-28,1849	0,0000	-2,2147	-1,9267	eigenvector
C(coorte)[T.2000]	-2,1104	0,0735	-28,6968	0,0000	-2,2546	-1,9663	eigenvector
C(coorte)[T.2010]	-2,0327	0,0737	-27,5984	0,0000	-2,1770	-1,8883	eigenvector
C(coorte)[T.2020]	-1,7953	0,0763	-23,5242	0,0000	-1,9449	-1,6457	eigenvector
C(gender)[T.F]:C(genere)[T.Blues]	0,0528	0,2128	0,2483	0,8039	-0,3643	0,4700	eigenvector
C(gender)[T.F]:C(genere)[T.Children's]	-0,1451	0,2392	-0,6068	0,5440	-0,6138	0,3236	eigenvector
C(gender)[T.F]:C(genere)[T.Classical]	0,0347	0,1850	0,1875	0,8513	-0,3279	0,3973	eigenvector
C(gender)[T.F]:C(genere)[T.Electronic]	-0,0192	0,1768	-0,1085	0,9136	-0,3657	0,3274	eigenvector
C(gender)[T.F]:C(genere)[T.Folk, World, & Country]	-0,1365	0,1863	-0,7323	0,4640	-0,5016	0,2287	eigenvector
C(gender)[T.F]:C(genere)[T.Funk / Soul]	0,2858	0,2295	1,2451	0,2131	-0,1641	0,7357	eigenvector

Tabella — Posizione nella rete (eigenvector) per genere sessuale e genere musicale, a parità di attività e coorte

Mostrate le prime 28 righe di 35; la tabella completa è in `tables/`

`t3_regressione_eigenvector.csv` e `tables/t3_regressione_eigenvector.tex`.

termine	coef	se	z	p	ci_lo	ci_hi	esito
Intercept	1,1580	0,0329	35,2227	0,0000	1,0936	1,2224	coreness
C(gender)[T.F]	0,0362	0,0792	0,4572	0,6475	-0,1190	0,1915	coreness
C(genere)[T.Blues]	0,0051	0,0360	0,1416	0,8874	-0,0654	0,0756	coreness
C(genere)[T.Children's]	-0,0135	0,0396	-0,3415	0,7328	-0,0912	0,0642	coreness
C(genere)[T.Classical]	-0,2867	0,0278	-10,3191	0,0000	-0,3411	-0,2322	coreness
C(genere)[T.Electronic]	0,0474	0,0256	1,8549	0,0636	-0,0027	0,0976	coreness
C(genere)[T.Folk, World, & Country]	0,0516	0,0268	1,9281	0,0538	-0,0009	0,1041	coreness
C(genere)[T.Funk / Soul]	0,0480	0,0333	1,4400	0,1499	-0,0173	0,1134	coreness
C(genere)[T.Hip Hop]	0,3801	0,0291	13,0492	0,0000	0,3230	0,4372	coreness
C(genere)[T.Jazz]	0,1173	0,0273	4,2999	0,0000	0,0638	0,1707	coreness
C(genere)[T.Non-Music]	-0,1804	0,0366	-4,9333	0,0000	-0,2521	-0,1088	coreness
C(genere)[T.Pop]	0,1794	0,0260	6,9001	0,0000	0,1284	0,2304	coreness
C(genere)[T.Rock]	-0,0319	0,0255	-1,2487	0,2118	-0,0820	0,0182	coreness
C(genere)[T.Stage & Screen]	0,1865	0,0345	5,3991	0,0000	0,1188	0,2542	coreness
C(coorte)[T.1950]	0,0563	0,0249	2,2643	0,0236	0,0076	0,1051	coreness
C(coorte)[T.1960]	-0,0144	0,0219	-0,6585	0,5102	-0,0574	0,0286	coreness
C(coorte)[T.1970]	-0,1829	0,0216	-8,4552	0,0000	-0,2254	-0,1405	coreness
C(coorte)[T.1980]	-0,1984	0,0213	-9,3131	0,0000	-0,2401	-0,1566	coreness
C(coorte)[T.1990]	-0,2171	0,0213	-10,2125	0,0000	-0,2587	-0,1754	coreness
C(coorte)[T.2000]	-0,2610	0,0215	-12,1340	0,0000	-0,3031	-0,2188	coreness
C(coorte)[T.2010]	-0,3656	0,0222	-16,5025	0,0000	-0,4091	-0,3222	coreness
C(coorte)[T.2020]	-0,3616	0,0273	-13,2565	0,0000	-0,4151	-0,3082	coreness
C(gender)[T.F]:C(genere)[T.Blues]	-0,0177	0,1034	-0,1715	0,8638	-0,2204	0,1850	coreness
C(gender)[T.F]:C(genere)[T.Children's]	-0,0037	0,0927	-0,0396	0,9684	-0,1853	0,1780	coreness
C(gender)[T.F]:C(genere)[T.Classical]	-0,0692	0,0840	-0,8244	0,4097	-0,2338	0,0954	coreness
C(gender)[T.F]:C(genere)[T.Electronic]	-0,0092	0,0801	-0,1147	0,9087	-0,1661	0,1478	coreness
C(gender)[T.F]:C(genere)[T.Folk, World, & Country]	-0,0633	0,0834	-0,7589	0,4479	-0,2268	0,1002	coreness
C(gender)[T.F]:C(genere)[T.Funk / Soul]	-0,0660	0,1054	-0,6263	0,5311	-0,2725	0,1405	coreness

Tabella — Appartenenza al nucleo (coreness) per genere sessuale e genere musicale, a parità di attività e coorte

Mostrate le prime 28 righe di 35; la tabella completa è in `tables/t3_regressione_coreness.csv` e `tables/t3_regressione_coreness.tex`.

6.2 La risposta a RQ3

Il pattern “Smurfette” non si osserva in questi dati. A parità di pubblicazioni, coorte e genere musicale, l’effetto principale dell’essere donna sulla posizione nella rete non è distinguibile da zero su nessuna delle tre misure:

misura	coefficiente	IC 95%	p
eigenvector	0,180	-0,164 - 0,524	0,305
coreness	0,036	-0,119 - 0,191	0,648
betweenness	-0,293	-0,625 - 0,039	0,083

Nemmeno le interazioni con il genere musicale aiutano: su 12 termini di interazione stimati, 0 risultano significativi al 5%. Non esiste, in questi dati, una scena in cui essere donna sposti sistematicamente verso la periferia della rete.

È un risultato che va enunciato con precisione, perché si presta a due letture sbagliate di segno opposto.

Non significa che non ci sia disuguaglianza. Le donne sono il 14,8% della popolazione e pubblicano meno: la mediana delle pubblicazioni è 8 contro 9. La disuguaglianza c’è ed è grande — ma si manifesta **nell’accesso e nel volume di attività**, non nella posizione strutturale a parità di attività. Chi entra e riesce a lavorare, lavora in posizioni comparabili.

Non significa nemmeno che il controllo per l’attività sia neutro. Il numero di pubblicazioni non è una variabile esogena: è esso stesso un esito di processi di accesso che possono essere segregati. Controllare per l’attività risponde alla domanda “a parità di carriera, la posizione differisce?” e non alla domanda “le carriere differiscono?”. La prima ha risposta negativa, la seconda — sezione 4 — ha risposta ampiamente positiva.

Il dato più interessante è la divergenza fra mediana e media dell’eigenvector: la mediana è più alta per le donne ($7,7 \times 10^{-9}$ contro $3,9 \times 10^{-9}$) mentre la media è più bassa. Significa che la donna tipica della rete è connessa quanto e più dell’uomo tipico, ma che gli **hub estremi** — i pochissimi nodi con centralità di ordini di grandezza superiore — sono quasi tutti uomini. La disuguaglianza di posizione, dove c’è, sta nella coda, non nel corpo della distribuzione.

7. Probabilità di collaborare a parità di tutto: l'ERGM (RQ4)

7.1 Perché serve e come è stato impostato

Tutte le misure fin qui sono descrittive: dicono *che* i legami sono distribuiti in un certo modo, non *perché*. Un modello esponenziale per grafi casuali (ERGM) stima invece la probabilità che un legame esista, tenendo insieme nello stesso modello l'omofilia di genere, quella di genere musicale, il livello di attività, la coorte e la tendenza della rete a chiudere i triangoli. Quest'ultimo punto è decisivo: senza un termine di chiusura triadica (gwesp), qualunque tendenza a fare gruppo viene erroneamente attribuita all'attributo su cui si sta guardando.

Sulla rete intera l'ERGM non è stimabile, e va detto chiaramente invece di far finta. Con 70.712 nodi lo spazio dei grafi possibili rende il campionamento MCMC impraticabile. Si è quindi proceduto come previsto dal disegno, per sottoreti: i cinque generi musicali più popolosi, le due epoche, e un campione a palla di neve della rete complessiva come riferimento. **Le stime valgono per le sottoreti su cui sono calcolate**, non si estendono per costruzione all'intera popolazione.

Dall'ERGM sono esclusi i nodi con genere `unknown`. Tenerli come quarta categoria avrebbe prodotto un termine di omofilia spurio che misura la struttura della copertura dei dati — chi è poco documentato collabora con chi è poco documentato — invece della struttura delle collaborazioni.

Si stima una **gerarchia di tre modelli**, invece di una specifica unica, perché il termine di chiusura triadica è esattamente quello che può far fallire la stima e non si vuole perdere tutto insieme a lui:

- **M0** `edges + nodematch(gender, diff) + controlli` — nessun termine di dipendenza fra archi. È il modello di riferimento: stimabile sempre.
- **M1** `M0 + gwesp(0,25; fixed)` — la specifica prevista dal disegno. Il termine di chiusura triadica rende il modello quasi degenere sulle reti molto clusterizzate, e può non convergere.
- **M2** come il migliore fra M1 e M0, con `nodemix(gender)` al posto di `nodematch(gender, diff)`. Le due parametrizzazioni sono ridondanti fra loro e nello stesso modello lo renderebbero non identificato.

I termini di controllo entrano **solo se l'attributo varia** nella sottorete. Dentro una sottorete di un solo genere musicale `nodematch('musical_genre')` coincide identicamente con `edges`: includerlo produrrebbe un modello non identificato, e nelle prime esecuzioni era proprio questo a impedire la convergenza.


rete	nodi_originali	nodi_stimati	archi	campionata	convergenza	modelli_convergenza
genere_Electronic	10.499	1.255	4.968	True	True	M0_senza_gwesp, M1_con_gwesp, M2_nodemix_gwesp
genere_Rock	4.938	1.438	4.972	True	True	M0_senza_gwesp, M1_con_gwesp, M2_nodemix_gwesp
genere_Pop	5.236	1.057	4.989	True	True	M0_senza_gwesp, M1_con_gwesp, M2_nodemix_gwesp
genere_Folk_World_&_Country	1.625	1.033	4.931	True	True	M0_senza_gwesp, M1_con_gwesp, M2_nodemix_gwesp
genere_Classical	673	673	1.620	False	True	M0_senza_gwesp, M1_con_gwesp, M2_nodemix_gwesp
epoca_pre2000	23.491	1.303	4.962	True	True	M0_senza_gwesp, M1_con_gwesp, M2_nodemix_gwesp
epoca_post2000	9.400	1.373	4.961	True	True	M0_senza_gwesp, M1_con_gwesp, M2_nodemix_gwesp
complessiva	36.388	722	4.982	True	True	M0_senza_gwesp, M1_con_gwesp, M2_nodemix_gwesp

Tabella — Sintesi delle stime ERGM: dimensione, campionamento, convergenza

Dati completi in `tables/t4_ergm_sintesi.csv` e `tables/t4_ergm_sintesi.tex`.

Sottoreti con almeno un modello convergente: **8 su 8**; sottoreti in cui ha retto anche il termine gwesp: **8**. Dove gwesp non converge, i coefficienti riportati vengono da M0 e **non** controllano per la chiusura triadica: vanno quindi letti come stime che possono attribuire all'omofilia una parte di ciò che è semplicemente tendenza a formare triangoli. È una limitazione, ed è dichiarata qui invece di essere nascosta dietro un numero.

Omofilia di genere a parità di attività, coorte e chiusura triadica nei cinque generi musicali più popolari



Coefficienti di omofilia di genere nei cinque generi musicali più popolari. Ogni coefficiente è un log-odds: quanto la probabilità di un legame aumenta (o diminuisce) se due artisti condividono il genere sessuale, *a parità* di attività, coorte, genere musicale e chiusura triadica. Questo è il confronto che le misure descrittive della sezione 5.4 non potevano fornire: qui i coefficienti maschile e femminile sono sulla stessa scala e sono direttamente confrontabili, perché misurano una propensione e non un rapporto osservato/atteso schiacciato dalle marginali. Se il coefficiente maschile supera quello femminile, il pattern italiano è allineato alla letteratura (omofilia più forte fra gli uomini) e l'inversione osservata nella sezione 5.4 era un artefatto della rarità delle donne.

rete	model	term	estimate	se	p	ci_lo	ci_hi
genere_Electronic	M0_senza_gwesp	edges	-9,6104	0,0947	-101,4612	-9,7961	-9,424
genere_Electronic	M0_senza_gwesp	nodematch.gender.F	0,6501	0,1016	6,3982	0,4509	0,8492
genere_Electronic	M0_senza_gwesp	nodematch.gender.M	0,1548	0,0343	4,5141	0,0876	0,2220
genere_Electronic	M0_senza_gwesp	nodematch.gender.mixed	1,7995	0,2002	8,9895	1,4072	2,1919
genere_Electronic	M0_senza_gwesp	nodecov.log_nrel	0,4587	0,0096	47,5998	0,4398	0,4776
genere_Electronic	M0_senza_gwesp	nodematch.cohort_decade	0,9364	0,0286	32,7475	0,8803	0,9924
genere_Electronic	M1_con_gwesp	edges	-8,3712	0,0990	-84,5544	-8,5653	-8,177
genere_Electronic	M1_con_gwesp	nodematch.gender.F	0,4771	0,0889	5,3685	0,3029	0,6513
genere_Electronic	M1_con_gwesp	nodematch.gender.M	0,0978	0,0244	4,0055	0,0499	0,1456
genere_Electronic	M1_con_gwesp	nodematch.gender.mixed	1,5036	0,1510	9,9574	1,2076	1,7996
genere_Electronic	M1_con_gwesp	nodecov.log_nrel	0,1270	0,0081	15,7610	0,1112	0,1428
genere_Electronic	M1_con_gwesp	nodematch.cohort_decade	0,5027	0,0332	15,1581	0,4377	0,5677
genere_Electronic	M1_con_gwesp	gwesp.fixed.0.25	2,3216	0,0627	37,0510	2,1988	2,4444
genere_Electronic	M2_nodemix_gwesp	edges	-7,5427	0,1086	-69,4677	-7,7556	-7,329
genere_Electronic	M2_nodemix_gwesp	mix.gender.F.M	-0,8361	0,0598	-13,9753	-0,9534	-0,718
genere_Electronic	M2_nodemix_gwesp	mix.gender.M.M	-0,6619	0,0618	-10,7108	-0,7830	-0,540
genere_Electronic	M2_nodemix_gwesp	mix.gender.F.mixed	-0,3314	0,1478	-2,2426	-0,6210	-0,041
genere_Electronic	M2_nodemix_gwesp	mix.gender.M.mixed	-0,7559	0,0811	-9,3256	-0,9148	-0,597
genere_Electronic	M2_nodemix_gwesp	mix.gender.mixed.mixed	0,5991	0,1927	3,1092	0,2214	0,9767
genere_Electronic	M2_nodemix_gwesp	nodecov.log_nrel	0,1282	0,0084	15,1873	0,1116	0,1447
genere_Electronic	M2_nodemix_gwesp	nodematch.cohort_decade	0,5610	0,0259	21,6217	0,5101	0,6118
genere_Electronic	M2_nodemix_gwesp	gwesp.fixed.0.25	2,1816	0,0703	31,0263	2,0437	2,3194
genere_Rock	M0_senza_gwesp	edges	-9,3291	0,0768	-121,5302	-9,4796	-9,178
genere_Rock	M0_senza_gwesp	nodematch.gender.F	0,8337	0,2548	3,2716	0,3342	1,3331
genere_Rock	M0_senza_gwesp	nodematch.gender.M	-0,1000	0,0402	-2,4897	-0,1788	-0,021
genere_Rock	M0_senza_gwesp	nodematch.gender.mixed	1,2413	0,2113	5,8744	0,8271	1,6554
genere_Rock	M0_senza_gwesp	nodecov.log_nrel	0,4589	0,0080	57,4936	0,4433	0,4746
genere_Rock	M0_senza_gwesp	nodematch.cohort_decade	1,3306	0,0286	46,5589	1,2746	1,3867
genere_Rock	M1_con_gwesp	edges	-10,3651	0,1100	-94,2404	-10,5806	-10,14
genere_Rock	M1_con_gwesp	nodematch.gender.F	0,7312	0,1842	3,9686	0,3701	1,0922
genere_Rock	M1_con_gwesp	nodematch.gender.M	-0,0756	0,0240	-3,1486	-0,1227	-0,028
genere_Rock	M1_con_gwesp	nodematch.gender.mixed	-0,5234	0,3615	-1,4479	-1,2319	0,1851
genere_Rock	M1_con_gwesp	nodecov.log_nrel	0,0913	0,0046	19,7145	0,0823	0,1004
genere_Rock	M1_con_gwesp	nodematch.cohort_decade	0,7956	0,0220	36,1783	0,7525	0,8387
genere_Rock	M1_con_gwesp	gwesp.fixed.0.25	4,4500	0,0733	60,7193	4,3064	4,5936

rete	model	term	estimate	se	p	ci_lo	ci_hi
genere_Rock	M2_nodemix_gwesp	edges	-9,8962	0,3335	-29,6768	-10,5498	-9,242
genere_Rock	M2_nodemix_gwesp	mix.gender.F.M	-0,3735	0,3349	-1,1153	-1,0299	0,2829
genere_Rock	M2_nodemix_gwesp	mix.gender.M.M	-0,5840	0,3462	-1,6868	-1,2626	0,0946
genere_Rock	M2_nodemix_gwesp	mix.gender.F.mixed	-0,9523	0,3283	-2,9006	-1,5958	-0,308
genere_Rock	M2_nodemix_gwesp	mix.gender.M.mixed	-0,5631	0,3339	-1,6863	-1,2176	0,0914

Tabella — Coefficienti ERGM per sottorete

Mostrate le prime 40 righe di 185; la tabella completa è in `tables/t4_ergm_coefficienti.csv` e `tables/t4_ergm_coefficienti.tex`.

Come si leggono questi coefficienti, e che cosa dicono


I coefficienti sono in log-odds; la colonna `or` è il loro esponenziale, cioè di quanto si moltiplica la probabilità di un legame. `nodematch.gender.F` dice quanto una coppia donna-donna è più probabile di una coppia di riferimento **a parità di tutto il resto**: attività, coorte, genere musicale e — cosa decisiva — tendenza della rete a chiudere i triangoli.

Il confronto fra `nodematch.gender.F` e `nodematch.gender.M` è il risultato che la sezione 5.4 non poteva dare. Lì i rapporti osservato/atteso non erano confrontabili, perché con una quota femminile del 14,8% il valore atteso per un legame donna-donna è così basso che qualunque addensamento reale produce un rapporto grande. Qui il problema non si pone: i due coefficienti misurano la stessa quantità sulla stessa scala. **E il risultato regge: la propensione delle donne a lavorare con donne resta nettamente superiore a quella degli uomini a lavorare con uomini.** Non è un artefatto della rarità; è una proprietà della rete.

In alcune sottoreti il coefficiente maschile è **negativo**: a parità di tutto il resto, due uomini hanno una probabilità di collaborare leggermente *inferiore* al riferimento. Non significa che gli uomini si evitino. Significa che, in un ambiente dove sono la stragrande maggioranza, il termine `edges` da solo già produce quasi tutti i legami maschili che si osservano, e una volta tolta quella quota di base non resta nulla da attribuire a una preferenza. È la controprova, dal lato opposto, della stessa asimmetria: dove un gruppo domina, l'omofilia non ha modo di manifestarsi come effetto misurabile; dove un gruppo è raro, si manifesta con forza.

Merita attenzione anche il confronto fra M0 e M1. Passando dal modello senza chiusura triadica a quello con `gwesp`, il coefficiente di omofilia femminile **si riduce**: una parte di ciò che sembrava preferenza di genere era in realtà la tendenza generale della rete a chiudere i triangoli — se A lavora con B e B con C, prima o poi A lavora con C, e in un ambiente dove le donne sono poche i triangoli fra donne si formano comunque. Il termine `gwesp` ha un coefficiente molto grande, il che dice quanto forte sia quel meccanismo. Ciò che resta dopo averlo tolto è omofilia vera.

7.2 La diagnostica: il modello descrive davvero questa rete?



Bontà di adattamento. Per ciascuna sottorete si confrontano tre statistiche della rete osservata (punti) con quelle delle reti simulate dal modello stimato (linea e banda): la distribuzione dei gradi, il numero di partner condivisi da ciascuna coppia collegata (ESP) e le distanze geodetiche. Un modello che coglie la struttura produce simulazioni la cui banda contiene l'osservato; dove il punto esce dalla banda, il modello sta sbagliando proprio quell'aspetto. L'ESP è la statistica da guardare con più attenzione, perché è quella che il termine gwesp dovrebbe riprodurre: se l'osservato ne esce, la chiusura triadica non è stata catturata e i coefficienti di omofilia possono averne assorbito una parte. Nei modelli stimati qui il centro delle distribuzioni è riprodotto bene, ma **la coda no**: i nodi con molti collaboratori e le coppie con molti partner in comune sono sistematicamente più numerosi di quanto il modello preveda (cerchi rossi). È il limite noto degli ERGM su reti con code pesanti, e va tenuto presente leggendo i coefficienti: il modello descrive bene il musicista tipico, meno bene i pochi grandi collaboratori.

Tabella «t4_ergm_mcmc» non disponibile.

7.3 Il test pre/post 2000

model	term	estimate_pre	estimate_post	differenza	se_diff	z	p
M0_senza_gwesp	edges	-10,1834	-10,1231	0,0603	0,1294	0,4657	0,64
M0_senza_gwesp	nodematch.gender.F	0,6129	0,3757	-0,2372	0,2690	-0,8817	0,37
M0_senza_gwesp	nodematch.gender.M	0,0546	0,1506	0,0960	0,0595	1,6145	0,10
M0_senza_gwesp	nodematch.gender.mixed	1,1725	1,8788	0,7063	1,0520	0,6714	0,50
M0_senza_gwesp	nodematch.musical_genre	1,8584	0,7809	-1,0775	0,0577	-18,6881	0,00
M0_senza_gwesp	nodecov.log_nrel	0,3983	0,4749	0,0766	0,0127	6,0327	0,00
M0_senza_gwesp	nodematch.cohort_decade	0,9962	0,8471	-0,1491	0,0465	-3,2085	0,00
M1_con_gwesp	edges	-8,9452	-8,7947	0,1506	0,1833	0,8216	0,41
M1_con_gwesp	nodematch.gender.F	0,7092	0,7763	0,0671	0,4368	0,1536	0,87
M1_con_gwesp	nodematch.gender.M	0,1368	0,0797	-0,0571	0,1091	-0,5234	0,60
M1_con_gwesp	nodematch.gender.mixed	1,2087	0,6167	-0,5920	1,3414	-0,4414	0,65
M1_con_gwesp	nodematch.musical_genre	0,9938	0,2883	-0,7055	0,0936	-7,5364	0,00
M1_con_gwesp	nodecov.log_nrel	0,1385	0,0803	-0,0582	0,0214	-2,7217	0,00
M1_con_gwesp	nodematch.cohort_decade	0,4768	0,3040	-0,1727	0,0844	-2,0462	0,04
M1_con_gwesp	gwesp.fixed.0.25	2,2169	2,8923	0,6754	0,0799	8,4490	0,00
M2_nodemix_gwesp	edges	-7,8019	-7,9375	-0,1357	0,3456	-0,3926	0,69
M2_nodemix_gwesp	mix.gender.F.M	-0,7275	-0,8898	-0,1623	0,3460	-0,4692	0,63
M2_nodemix_gwesp	mix.gender.M.M	-0,6808	-0,7937	-0,1129	0,3290	-0,3432	0,73
M2_nodemix_gwesp	mix.gender.F.mixed	-1,0455	0,0598	1,1053	0,6258	1,7661	0,07
M2_nodemix_gwesp	mix.gender.M.mixed	-1,0852	-0,9688	0,1164	0,4379	0,2659	0,79
M2_nodemix_gwesp	mix.gender.mixed.mixed	0,0206	0,2712	0,2506	3,2202	0,0778	0,93
M2_nodemix_gwesp	nodematch.musical_genre	1,0659	0,2194	-0,8465	0,0710	-11,9154	0,00
M2_nodemix_gwesp	nodecov.log_nrel	0,1052	0,0968	-0,0084	0,0179	-0,4684	0,63
M2_nodemix_gwesp	nodematch.cohort_decade	0,5239	0,3121	-0,2118	0,0677	-3,1283	0,00
M2_nodemix_gwesp	gwesp.fixed.0.25	2,1250	2,8679	0,7429	0,0908	8,1822	0,00

Tabella — Test della differenza fra i coefficienti ERGM pre-2000 e post-2000

Dati completi in tables/t4_ergm_differenza_epoche.csv e tables/t4_ergm_differenza_epoche.tex.

Questa tabella è la verifica formale del risultato controintuitivo della sezione 5.2, e il suo esito è netto.


L'omofilia di genere non cambia fra le due epoche. Per le donne il coefficiente passa da 0,709 a 0,776 (differenza 0,067, $p = 0,88$); per gli uomini da 0,137 a 0,080 (differenza -0,057, $p = 0,60$). Nessuna delle due differenze si avvicina alla significatività.

Cambia invece, e moltissimo, la chiusura triadica. Il coefficiente gw_{esp} passa da 2,217 a 2,892, una differenza di 0,675 con $p < 0,0001$: è l'unico termine del modello la cui variazione fra epoche sia statisticamente solida.

La lettura congiunta è quella data alla sezione 5.2: l'aumento dell'assortatività osservata dopo il 2000 non è un rafforzamento della preferenza di genere, ma la conseguenza di una rete che si chiude in gruppi più fitti. Vale la pena notare che questo è esattamente il tipo di confusione che un'analisi puramente descrittiva non può sciogliere, e per cui l'ERGM era previsto nel disegno.

8. Quanto reggono questi risultati

8.1 L'incertezza sul genere sessuale



La distribuzione Monte Carlo dell'assortatività di genere al variare dell'imputazione degli 22.136 artisti senza genere determinato. L'istogramma è la distribuzione su 200 estrazioni dalla marginale osservata. Le due linee tratteggiate laterali non sono stime ma **limiti costruiti apposta**: assegnando a ogni artista ignoto il genere prevalente fra i suoi collaboratori si ottiene la massima omofilia compatibile con i dati; assegnando il genere opposto si ottiene la minima. Il fatto rilevante è che **anche il limite inferiore resta positivo**: non esiste assegnazione degli ignoti che faccia sparire l'omofilia. La conclusione qualitativa è robusta; la sua grandezza esatta no.

scenario	count	mean	std	min	max	ci_lo	ci_hi
migliore_omofilia_min	1	0,0499	n.d.	0,0499	0,0499	n.d.	n.d.
peggiore_omofilia_max	1	0,0623	n.d.	0,0623	0,0623	n.d.	n.d.
solo_noti	1	0,0432	n.d.	0,0432	0,0432	n.d.	n.d.
status_quo	200	0,0329	0,0007	0,0308	0,0349	0,0313	0,0343

Tabella — Assortatività di genere sotto diversi scenari di imputazione


Dati completi in `tables/t5_montecarlo_genere.csv` e `tables/t5_montecarlo_genere.tex`.

I quattro numeri vanno letti insieme. Sui soli artisti con genere determinato l'assortatività vale 0,0432. Imputando gli ignoti per estrazione casuale dalla marginale osservata scende a 0,0329: l'imputazione casuale non può che diluire la struttura, ed è la ragione per cui la misura di riferimento di questo studio è la prima e non la seconda. I due limiti costruiti sul vicinato — 0,0499 e 0,0623 — delimitano quanto l'omofilia potrebbe valere se gli

artisti ignoti somigliassero sistematicamente ai loro collaboratori o sistematicamente no. **Nessuno dei quattro scenari porta l'omofilia a zero o sotto zero.**

Va detto con precisione che cosa questi limiti non fanno: riguardano solo gli artisti ignoti che hanno almeno un collaboratore di genere noto. Quelli che collaborano soltanto con altri ignoti non portano informazione utilizzabile e vengono estratti dalla marginale anche negli scenari estremi — assegnarli per maggioranza del vicinato li metterebbe tutti nella stessa categoria, creando un blocco artificiale che gonfierebbe *entrambi* gli estremi invece di delimitarli.

8.2 Sensibilità ai parametri di costruzione



Ogni punto è l'assortatività di genere ottenuta cambiando un solo parametro rispetto alla configurazione di default (linea tratteggiata). Gli assi variati sono quelli che potevano ragionevolmente cambiare il risultato: quanti artisti al massimo può avere una pubblicazione perché conti come collaborazione, quale peso minimo deve avere un arco, se escludere le raccolte, quanto strettamente definire l'italianità, come pesare la specificità dei crediti, e se usare o no i crediti a livello traccia. Quest'ultimo è l'asse più informativo: disattivare i crediti di traccia significa tornare a una rete costruita solo sulle co-presenze di copertina, ed è il confronto che dice quanto il livello traccia stia effettivamente aggiungendo.

variante	nodi	archi	gigante	r genere M/ F	r pesata	r gen. musicale
default	70.712	586.040	0,9538	0,0432	0,1254	0,4970
max_credits=4	50.042	204.330	0,9012	0,0327	0,1226	0,5278
max_credits=20	80.864	1.445.126	0,9702	0,0500	0,1368	0,4512
peso_min_arco=1.0	44.938	314.348	0,9133	0,0675	0,1329	0,5529
peso_min_arco=2.0	33.840	159.715	0,8569	0,0631	0,1260	0,5966
raccolte_escluse=True	65.549	508.524	0,9503	0,0459	0,1303	0,5037
crediti_traccia=False	69.806	546.310	0,9518	0,0442	0,0892	0,5006
pesi_specificita=1.0/1.0/1.0	70.712	586.040	0,9538	0,0432	0,1086	0,4970
pesi_specificita=1.0/0.5/0.1	70.712	586.040	0,9538	0,0432	0,1336	0,4970
soglia_italianita=0.6	63.488	500.418	0,9527	0,0461	0,1254	0,4875
soglia_italianita=0.7	53.916	390.999	0,9507	0,0450	0,1331	0,4795

Tabella — Sensibilità delle metriche chiave ai parametri di costruzione della rete

Dati completi in tables/t5_sensibilita.csv e tables/t5_sensibilita.tex.

Sulle 10 varianti provate, l'assortatività di genere sui soli nodi determinati resta compresa fra **0,0327 e 0,0675**, sempre positiva e sempre dello stesso ordine di grandezza del valore di riferimento (0,0432). Nessuna scelta di costruzione della rete, fra quelle difendibili, ribalta la conclusione.

Che cosa aggiungono davvero i crediti a livello traccia

La colonna dell'assortatività **pesata** è l'unica su cui la gerarchia di specificità dei crediti può manifestarsi, perché cambiare i pesi non cambia quali coppie di artisti siano collegate: cambia quanto contano. Il confronto è istruttivo.

- con i crediti di traccia e la gerarchia di default: **0,1254**
- senza crediti di traccia, cioè tornando alle sole co-presenze di copertina: **0,0892**
- con tutti i crediti allo stesso peso: 0,1086
- con una gerarchia più ripida (1 / 0,5 / 0,1): 0,1336

Disattivare il livello traccia abbassa l'omofilia misurata di circa 29%, e appiattire i pesi la abbassa quasi altrettanto. La lettura è che **le collaborazioni documentate in modo più specifico sono anche le più omofile**: quando due nomi compaiono insieme sulla stessa traccia — non genericamente sullo stesso disco — la probabilità che condividano il genere sessuale è più alta. Una rete costruita sulle sole co-presenze di copertina sottostima quindi la segregazione, perché mescola la collaborazione vera con la coabitazione editoriale. È la giustificazione empirica della scelta di disegno descritta alla sezione 3.1.

8.3 Artisti con genere musicale debole

variante	nodi	archi	densita	quota_gigante	r_gender	r_gender_MF	r_gender_pesato	r_genere
genre_top1	70.712	586.040	0,0002	0,9538	0,0810	0,0432	0,1254	0,4970
genre_top2	70.712	586.040	0,0002	0,9538	0,0810	0,0432	0,1254	0,4538
genre_exclude	45.704	349.998	0,0003	0,9505	0,0822	0,0486	0,1234	0,7045

Tabella — Metriche chiave usando il tag principale, il secondo tag, o escludendo gli artisti con attribuzione debole

Dati completi in `tables/t5_genere_debole.csv` e `tables/t5_genere_debole.tex`.

Gli artisti il cui tag di genere principale copre meno del 40% delle loro pubblicazioni sono marcati `genre_weak`: sono 30.724, cioè 35,2% della popolazione. La tabella confronta tre trattamenti — tenerli col tag principale, sostituirlo col secondo tag, escluderli del tutto — per mostrare quanto le conclusioni su RQ2 dipendano da un’attribuzione di genere musicale che per costruzione è incerta.

Appendice tecnica

A.1 Ambiente

- Sistema: Linux-5.15.0-185-generic-x86_64-with-glibc2.35
- Python 3.9.12
- PostgreSQL 18.4 — database discogs, dati su disco rotazionale
- R per l'ERGM: installato in userspace via micromamba (conda-forge), env opt/mamba/envs/ergm
- Seme casuale globale: **20260920**
- Data di esecuzione: 25/09/2026

pacchetto	versione
gender_guesser	presente
matplotlib	3.8.1
networkx	3.2.1
numpy	1.24.2
pandas	1.5.3
psycpg2	2.9.10 (dt dec pq3 ext lo64)
pyarrow	18.1.0
scipy	1.11.3
seaborn	0.13.2
statsmodels	0.14.6

A.2 Una nota sulle prestazioni che ha condizionato il disegno

Il cluster PostgreSQL risiede su un disco **rotazionale** ma era configurato con `random_page_cost = 1.1`, un valore tarato per dischi a stato solido. Con quel costo il pianificatore preferisce percorsi ad accesso casuale che su disco meccanico degradano a pochi megabyte al secondo: la prima versione dell'estrazione girava a circa 5 MB/s. Le sessioni di estrazione impostano perciò `random_page_cost = 4` e riducono il parallelismo, favorendo scansioni sequenziali, e i conteggi di italianità sono stati riscritti come **una sola passata aggregata** su `release_artist` invece di due join ripetuti. Sono GUC di sessione: non modificano la configurazione del server né i dati.

Analogamente, il calcolo della matrice di mixing è stato riscritto da `numpy.add.at` a `numpy.bincount` su indici appiattiti — risultato numerico identico, verificato, circa **50 volte più veloce** — perché senza quella riscrittura le migliaia di repliche bootstrap e di modello nullo previste dal disegno non sarebbero state praticabili.

A.3 Query principali

Tutte le interrogazioni sono in `src/phase1_extract.py`. La più importante è quella che definisce la popolazione, in una passata sola:

```
SELECT ra.artist_id,  
       count(*) FILTER (WHERE it.id IS NOT NULL) AS n_it,  
       count(*) AS n_all  
FROM release_artist ra  
LEFT JOIN (SELECT id FROM release WHERE country = 'Italy') it  
ON it.id = ra.release_id  
GROUP BY 1  
HAVING count(*) FILTER (WHERE it.id IS NOT NULL) >= 2;
```

La selezione finale (quota, minimo di pubblicazioni, esclusioni anagrafiche) avviene poi sui dati già a terra, così che la Fase 5 possa variare le soglie senza rileggere il database.

A.4 Tempi di esecuzione

step	seconds
ERGM gwesp025_gwdeg	45.780,5
ERGM 2020s	13.466,7
ERGM 1950s	10.928,0
ERGM decay_alto	8.509,8
logit esatto su tutte le diadi	8.014,7
serie temporale esatta	5.449,4
betweenness	5.238,8
ERGM 1960s	4.602,8
ERGM gwesp050_stocapp	4.406,4
ERGM gwesp_esp0	3.585,5
rete intera: 20 riproiezioni randomizzate	3.342,4
ERGM genere_Rock	3.183,3
sensibilità	2.578,6
ERGM 1940s	2.468,0
ERGM due_scale	1.687,4
ERGM genere_Folk_World_&_Country	1.643,7
ERGM epoca_post2000	1.612,0
ERGM complessiva	1.573,4
ERGM genere_Electronic	1.485,7
passata 1b (ricerca di linea)	1.460,8

A.5 Riproducibilità

```
cd /media/disk2/datascience/analysis/gender_collab
./run_all.sh                # esecuzione completa
./run_all.sh --from 3       # riparte dalla Fase 3
./run_all.sh --force        # ignora i checkpoint e ricalcola tutto
```

Ogni fase scrive un checkpoint in data/*.parquet e viene saltata se il checkpoint esiste. I dati grezzi estratti stanno in data/raw/, le figure in report/figures/, le tabelle in report/tables/ sia in CSV sia in LaTeX.

A.6 Limiti, in ordine di gravità

1. **Il genere sessuale è inferito, e la validazione manuale non è stata eseguita.** Il campione stratificato e lo script di scoring sono pronti; senza di essa l'errore di misura dell'inferenza resta non quantificato.
2. **L'italianità è approssimata dal paese di pubblicazione,** perché release_label è vuota. Confonde "artista italiano" con "artista pubblicato in Italia".
3. **26,9% della popolazione non ha genere musicale,** perché release_genre è vuota e i master coprono solo parte delle pubblicazioni.
4. **Nessuna verifica incrociata fra fonti:** iTunes è escluso per scelta.
5. **Discogs non è un censimento.** Sovrarappresenta vinile, elettronica e collezionismo.
6. **L'ERGM vale sulle sottoreti stimate,** non sull'intera rete.
7. **Wikidata copre 6,0% della popolazione;** il livello di recupero per nome non è stato completato per indisponibilità ripetuta del servizio SPARQL, che ha risposto con errori 429, 502 e 504.